

Relatório Final: Seleção de Modelo de IA para Módulo de Análise Textual

Micro-capstone de pós-graduação. Benchmark comparativo de modelos de IA para produto SaaS B2B.

Modelos avaliados: DeepSeek V4 Flash, Kimi K2.7 e Kimi K3.

Status do benchmark: executado na plataforma OpenCode com 5 tickets, 3 modelos e 3 execuções em lote por modelo. Os resultados foram preenchidos a partir dos logs reais de execução. O DeepSeek V4 Flash teve uma execução descartada por instabilidade de rede e três execuções válidas, sendo uma na camada gratuita e duas no plano pago. O Kimi K2.7 e o Kimi K3 tiveram três execuções válidas cada.

1. Capa

Título: Seleção de Modelo de IA para Módulo de Análise Textual em Produto SaaS B2B.

Subtítulo: Benchmark comparativo entre DeepSeek V4 Flash, Kimi K2.7 e Kimi K3.

Tarefa empresarial: Análise automatizada de tickets e feedbacks de clientes.

Autor: Daniel Felipe Tomm.

Data: 30 de julho de 2026.

2. Contexto empresarial

Uma startup B2B SaaS deseja adicionar inteligência artificial a um módulo de análise textual do produto. Esse módulo interpreta tickets de suporte e feedbacks de clientes. A decisão de qual modelo adotar afeta diretamente a margem do produto, pois o custo por requisição se multiplica pelo volume de tickets. A decisão também afeta a experiência do usuário, a escalabilidade da operação, a confiabilidade das classificações e o custo operacional de suporte.

A empresa precisa escolher o modelo que ofereça o melhor equilíbrio entre desempenho técnico e viabilidade econômica, considerando ainda o risco empresarial de automatizar decisões de atendimento.

3. Objetivo do benchmark

O objetivo é comparar os modelos DeepSeek V4 Flash, Kimi K2.7 e Kimi K3 em qualidade, custo, velocidade, consistência, adequação ao formato e risco de erro. A comparação deve fundamentar uma recomendação de adoção para a tarefa de negócio definida.

Hipótese de trabalho: modelos com maior custo podem apresentar melhor qualidade, mas o ganho pode não justificar o impacto econômico no produto SaaS.

4. Descrição da tarefa

Cada modelo recebe um texto de ticket ou feedback de cliente e deve produzir uma análise estruturada exclusivamente em JSON válido. A análise contém resumo do problema, categoria do ticket, sentimento, urgência, risco de churn, ação recomendada, tom sugerido para a resposta e justificativa da classificação.

Esse caso de uso permite priorizar atendimentos, encaminhar tickets às equipes corretas, detectar clientes com risco de cancelamento, reduzir trabalho manual de triagem, melhorar o tempo de resposta e apoiar atendentes humanos.

A estrutura completa da saída esperada, as categorias permitidas e os riscos envolvidos estão detalhados no documento 01_descricao_tarefa_negocio.md.

5. Modelos avaliados

O DeepSeek V4 Flash foi executado com o identificador `deepseek-v4-flash` no plano pago e `deepseek-v4-flash-free` na camada gratuita, ambos via provedor `opencode-go` na plataforma OpenCode.

O Kimi K2.7 foi executado com o identificador `kimi-k2.7-code`, também via provedor `opencode-go` na plataforma OpenCode.

O Kimi K3 foi executado com o identificador `kimi-k3`, via provedor `opencode-go` na plataforma OpenCode.

6. Metodologia

O benchmark seguiu o plano detalhado no documento 02_plano_benchmark.md, com um desvio registrado. Em vez de uma execução individual por ticket, os 5 tickets foram enviados em um único prompt, em formato de lote, em cada execução.

Foram realizadas 10 execuções no total. O DeepSeek V4 Flash teve 4 execuções, sendo 1 descartada por instabilidade de rede, 1 válida na camada gratuita e 2 no plano pago. O Kimi K2.7 e o Kimi K3 tiveram 3 execuções válidas cada.

As métricas de qualidade, consistência e latência do DeepSeek consideram as 3 rodadas válidas. As métricas de custo consideram apenas as rodadas do plano pago, que é a configuração viável para produção. A camada gratuita tem teto de 200 requisições por dia.

A avaliação combinou métricas objetivas e avaliação humana com rubrica de 1 a 5. As métricas objetivas incluíram custo e tokens reportados pela plataforma, latência medida pelos timestamps, validade do JSON, acurácia contra gabarito e consistência entre rodadas. A decisão final utilizou critérios eliminatórios e uma pontuação ponderada de 0 a 100.

7. Dataset

Foram utilizados 5 tickets fictícios criados para a atividade, com gabarito de referência definido previamente.

O ticket 1 é um caso comum de erro 500 ao exportar relatório em PDF, classificado como problema técnico.

O ticket 2 é um caso comum de cobrança duplicada do plano anual.

O ticket 3 é um caso comum de dúvida de configuração de webhook, classificado como integração.

O ticket 4 é um caso ambíguo de reclamação de usabilidade com menção a avaliar outras opções na renovação.

O ticket 5 é um caso difícil e crítico de indisponibilidade de 3 horas no dia de fechamento, com ameaça explícita de cancelamento.

8. Condições de comparação

Todos os modelos utilizaram os mesmos 5 tickets.

Todos os modelos utilizaram o mesmo prompt padrão.

O formato de saída exigido era JSON conforme a especificação. O prompt exigiu esse formato. O DeepSeek cumpriu em 1 de 3 rodadas sem desvios. O Kimi K2.7 cumpriu em 2 de 3 rodadas. O Kimi K3 cumpriu em todas as rodadas.

A ordem dos testes foi a mesma para todos os modelos, dos tickets 1 a 5.

O limite máximo de resposta não foi controlado entre os modelos. Isso foi registrado como limitação.

A temperatura não foi configurada no OpenCode. Isso também foi registrado como limitação.

O plano previa uma execução por ticket por modelo. Ocorreu um desvio: as execuções foram feitas em lote, com 3 rodadas válidas por modelo. O DeepSeek teve 1 rodada gratuita e 2 pagas, após 1 descartada.

As condições de rede foram parcialmente atendidas. A primeira execução do DeepSeek foi descartada por suspeita de instabilidade de rede.

A medição de latência seguiu o mesmo critério em todas as execuções, usando os timestamps de criação e conclusão da plataforma.

9. Métricas

Custo por requisição: custo reportado pela plataforma para cada execução em lote de 5 tickets, reconciliado com os preços unitários por milhão de tokens. A média do DeepSeek considera apenas as rodadas pagas.

Latência: diferença entre os timestamps de criação e conclusão. Foram calculadas média, mediana e maior valor observado. Com 3 rodadas, o maior valor aproxima o percentil 95.

Qualidade: acurácia de categoria, sentimento, urgência e risco de churn contra o gabarito, por rodada e em média. Também foi registrada a qualidade média da avaliação humana em rubrica de 1 a 5.

Acurácia combinada de classificação: média simples das quatro acurácias por rodada. Esse indicador foi usado no critério eliminatório de 80%.

Consistência: percentual de tickets com classificação idêntica nos campos categoria, sentimento, urgência e risco de churn em todas as rodadas válidas do modelo.

Adequação ao formato e tom: validade do JSON no formato exigido, presença dos campos obrigatórios, uso dos valores permitidos e cobertura dos 5 tickets.

Risco percebido de erro: escala de 1, muito baixo, a 5, crítico.

Erros críticos: tickets sem resposta ou com erro que comprometeria a automação.

10. Resultados gerais

A tabela a seguir apresenta as métricas gerais dos três modelos.

Métrica: rodadas válidas. DeepSeek V4 Flash teve 3 rodadas válidas, sendo 1 gratuita e 2 pagas. Kimi K2.7 teve 3 rodadas válidas. Kimi K3 teve 3 rodadas válidas.

Métrica: tokens médios de entrada e saída. DeepSeek V4 Flash consumiu 3.076 tokens de entrada e 903 tokens de saída em média. Kimi K2.7 consumiu 5.177 tokens de entrada e 2.024 tokens de saída. Kimi K3 consumiu 5.725 tokens de entrada e 1.302 tokens de saída.

Métrica: custo médio por execução em lote de 5 tickets. DeepSeek V4 Flash custou 0,00109884 dólar nas rodadas pagas. Kimi K2.7 custou 0,01351936 dólar. Kimi K3 custou 0,07587480 dólar.

Métrica: latência média. DeepSeek V4 Flash apresentou 17.119 milissegundos. Kimi K2.7 apresentou 13.212 milissegundos. Kimi K3 apresentou 110.128 milissegundos.

Métrica: JSON válido no formato exigido. DeepSeek V4 Flash obteve 33,3%, ou 1 de 3 rodadas. Kimi K2.7 obteve 66,7%, ou 2 de 3 rodadas. Kimi K3 obteve 100%, ou 3 de 3 rodadas.

Métrica: consistência entre rodadas. DeepSeek V4 Flash obteve 40%. Kimi K2.7 obteve 60%. Kimi K3 obteve 60%.

Métrica: qualidade média em escala de 1 a 5. DeepSeek V4 Flash obteve 5,0. Kimi K2.7 obteve 4,0. Kimi K3 obteve 4,5.

Métrica: risco percebido em escala de 1 a 5. Os três modelos obtiveram nota 2.

Observações sobre o DeepSeek V4 Flash: as rodadas consumiram entre 680 e 954 tokens de reasoning, cobrados como tokens de saída. Duas rodadas reutilizaram cache de sessão, com 9.600 e 9.088 tokens, o que reduziu o custo. O modelo respondeu os 5 tickets em todas as rodadas válidas. Em duas rodadas, a resposta veio envolvida em bloco de código markdown com array JSON. Na terceira rodada, veio em JSON puro, mas com envelope de objeto por ticket, identificados como ticket_1 a ticket_5, em vez de array. O desvio de formato mostrou-se mitigável, mas a estrutura do envelope variou.

Observações sobre o Kimi K2.7: o modelo retornou JSON puro em 2 de 3 rodadas. Na terceira rodada, a resposta veio em bloco de código markdown.

Observações sobre o Kimi K3: o modelo retornou JSON puro em todas as rodadas. Ele consumiu entre 1.214 e 3.422 tokens de reasoning por rodada, o que explica as

latências elevadas, entre 81 e 148 segundos.

11. Comparação de qualidade

A tabela a seguir apresenta as métricas de qualidade dos três modelos.

Acurácia de categoria: os três modelos obtiveram 100%.

Acurácia de sentimento: os três modelos obtiveram 100%.

Acurácia de urgência, em média: DeepSeek V4 Flash obteve 86,7%. Kimi K2.7 obteve 40%. Kimi K3 obteve 60%.

Acurácia de risco de churn, em média: DeepSeek V4 Flash obteve 86,7%. Kimi K2.7 obteve 66,7%. Kimi K3 obteve 73,3%.

Acurácia combinada por rodada: DeepSeek V4 Flash obteve 100%, 85% e 95%. Kimi K2.7 obteve 75%, 80% e 70%. Kimi K3 obteve 90%, 80% e 80%.

Acurácia combinada média: DeepSeek V4 Flash obteve 93,3%. Kimi K2.7 obteve 75%. Kimi K3 obteve 83,3%.

Qualidade média da avaliação humana, em escala de 1 a 5: DeepSeek V4 Flash obteve 5,0. Kimi K2.7 obteve 4,0. Kimi K3 obteve 4,5.

Análise: os três modelos acertaram categoria e sentimento de todos os tickets em todas as rodadas. A diferenciação está na calibragem de urgência e churn. O DeepSeek V4 Flash obteve a melhor qualidade média do benchmark, com 93,3% de acurácia combinada. Suas rodadas foram 100%, 85% e 95%. As divergências concentraram-se na urgência dos tickets 1 e 2 na rodada paga intermediária e no churn do ticket 4 nas rodadas pagas.

O Kimi K3 manteve padrão estável de divergência, com urgência alta nos tickets 1 e 2 nas 3 rodadas e churn superestimado nos tickets 2 e 4 nas rodadas 2 e 3. Sua média foi 83,3%.

O Kimi K2.7 foi o mais propenso a superestimar urgência, com acurácia média de 40% nesse campo. Sua acurácia combinada média foi 75%. Com 3 rodadas e 5 tickets, o DeepSeek se consolida como líder em qualidade, embora a amostra ainda não permita conclusão estatística robusta.

12. Comparação de custo

Os preços por milhão de tokens são os vigentes na data do teste, 30 de julho de 2026, conforme tabela da plataforma.

Preço de entrada por milhão de tokens: DeepSeek V4 Flash custa 0,14 dólar. Kimi K2.7 custa 0,95 dólar. Kimi K3 custa 3,00 dólares.

Preço de saída por milhão de tokens: DeepSeek V4 Flash custa 0,28 dólar. Kimi K2.7 custa 4,00 dólares. Kimi K3 custa 15,00 dólares.

Preço de leitura de cache por milhão de tokens: DeepSeek V4 Flash custa 0,0028 dólar. Kimi K2.7 custa 0,19 dólar. Kimi K3 custa 0,30 dólar.

Limite da camada gratuita: aplica-se apenas ao DeepSeek V4 Flash na versão `deepseek-v4-flash-free`, com teto de 200 requisições por dia. Não se aplica ao Kimi K2.7 nem ao Kimi K3.

Custo médio por execução em lote de 5 tickets: DeepSeek V4 Flash custou 0,00109884 dólar. Kimi K2.7 custou 0,01351936 dólar. Kimi K3 custou 0,07587480 dólar.

Custo médio por ticket: DeepSeek V4 Flash custou 0,00021977 dólar. Kimi K2.7 custou 0,00270387 dólar. Kimi K3 custou 0,01517496 dólar.

Custo em 10 mil execuções: DeepSeek V4 Flash custaria 10,99 dólares. Kimi K2.7 custaria 135,19 dólares. Kimi K3 custaria 758,75 dólares.

Custo em 100 mil execuções: DeepSeek V4 Flash custaria 109,88 dólares. Kimi K2.7 custaria 1.351,94 dólares. Kimi K3 custaria 7.587,48 dólares.

Custo em 1 milhão de execuções: DeepSeek V4 Flash custaria 1.098,84 dólares. Kimi K2.7 custaria 13.519,36 dólares. Kimi K3 custaria 75.874,80 dólares.

Observação sobre o limite da camada gratuita: o teto de 200 requisições por dia aplica-se apenas à camada gratuita do DeepSeek V4 Flash. O plano pago não possui esse teto. A plataforma também exibe uma coluna Usage com valor de 60 dólares para o modelo, cujo significado não foi documentado neste teste.

Análise: o DeepSeek V4 Flash no plano pago é a opção mais barata, com custo médio de 0,00022 dólar por ticket. Isso representa cerca de 12 vezes menos que o Kimi K2.7 e 69 vezes menos que o Kimi K3. Em 1 milhão de execuções em lote, que equivalem a 5 milhões de tickets, o DeepSeek custaria cerca de 1,1 mil dólar, contra 13,5 mil dólares do Kimi K2.7 e 75,9 mil dólares do Kimi K3.

A camada gratuita do DeepSeek permanece utilizável para volumes de até 200 requisições por dia, o que equivale a aproximadamente 1 mil tickets por dia em lotes de 5. As projeções consideram a execução em lote de 5 tickets. Em produção, com uma requisição por ticket, os valores por ticket devem ser usados como base. Os preços e limites são os vigentes na data do teste e podem mudar.

13. Comparação de latência

A tabela a seguir apresenta as métricas de latência dos três modelos.

Latências por rodada em milissegundos: DeepSeek V4 Flash apresentou 19.492, 13.537 e 18.328. Kimi K2.7 apresentou 13.051, 11.487 e 15.099. Kimi K3 apresentou 101.318, 147.993 e 81.074.

Latência média em milissegundos: DeepSeek V4 Flash apresentou 17.119. Kimi K2.7 apresentou 13.212. Kimi K3 apresentou 110.128.

Latência mediana em milissegundos: DeepSeek V4 Flash apresentou 18.328. Kimi K2.7 apresentou 13.051. Kimi K3 apresentou 101.318.

Maior latência observada em milissegundos: DeepSeek V4 Flash apresentou 19.492. Kimi K2.7 apresentou 15.099. Kimi K3 apresentou 147.993.

Taxa de timeout: zero para os três modelos.

Taxa de erro técnico: zero para os três modelos.

Análise: Kimi K2.7 e DeepSeek V4 Flash ficam na mesma faixa de latência. O Kimi K2.7 apresentou média de 13,2 segundos e o DeepSeek apresentou média de 17,1 segundos. A dispersão do DeepSeek pode ter sido influenciada pela instabilidade de rede no período dos testes. Ambos são adequados a processamento assíncrono de tickets.

O Kimi K3 foi de 5 a 11 vezes mais lento, com latências entre 81 e 148 segundos e grande dispersão entre rodadas. A latência elevada ocorre em razão do volume variável de reasoning. O Kimi K3 é inviável para uso em tempo real e limitado para triagem em alto volume.

Com 3 rodadas, o percentil 95 foi aproximado pela maior latência observada.

14. Comparação de consistência

A consistência mede o percentual de tickets com classificação idêntica nos campos categoria, sentimento, urgência e risco de churn em todas as rodadas válidas do modelo.

Consistência entre rodadas: DeepSeek V4 Flash obteve 40%. Kimi K2.7 obteve 60%. Kimi K3 obteve 60%.

Tickets que variaram: os tickets 1, 2 e 4 variaram no DeepSeek V4 Flash. Os tickets 2 e 4 variaram no Kimi K2.7 e no Kimi K3.

Formato idêntico entre rodadas: DeepSeek V4 Flash não apresentou formato idêntico, pois 2 rodadas vieram com fence de bloco de código e o envelope variou. Kimi K2.7 também não apresentou formato idêntico, com fence em 1 de 3 rodadas. Kimi K3 apresentou formato idêntico, com JSON puro nas 3 rodadas.

Análise: nenhum modelo foi totalmente consistente. Os tickets 2 e 4 variaram em todos os modelos. Esses são casos em que a calibragem de urgência e churn exige mais julgamento. Isso reforça a necessidade de exemplos de calibragem no prompt e de revisão humana nesses perfis de ticket.

O DeepSeek apresentou a menor consistência de classificação, com 40%, incluindo variação adicional no ticket 1. O modelo também variou o formato da saída, com 2 rodadas em bloco de código com array e 1 rodada em JSON puro com envelope de objeto.

O Kimi K3 teve consistência de classificação igual à do Kimi K2.7, com 60%, mas formato perfeitamente estável. Foi o único modelo sem nenhum desvio de formato.

15. Adequação ao formato e ao tom

JSON válido no formato exigido: DeepSeek V4 Flash obteve 33,3%, ou 1 de 3 rodadas. Kimi K2.7 obteve 66,7%, ou 2 de 3 rodadas. Kimi K3 obteve 100%, ou 3 de 3 rodadas.

Adequação de tom e formato em escala de 1 a 5: DeepSeek V4 Flash obteve 4,0. Kimi K2.7 obteve 4,0. Kimi K3 obteve 5,0.

Análise: os três modelos interpretaram corretamente o lote em todas as rodadas, respondendo os 5 tickets com todos os campos e valores permitidos.

O DeepSeek V4 Flash envolveu a saída em bloco de código markdown em 2 de 3 rodadas. Na rodada conforme, usou envelope de objeto por ticket em vez de array. Essa interpretação é razoável para lote, mas diferente das demais, o que exige normalização na integração. O desvio é contornável com parser tolerante a fences e a envelopes alternativos, ou com exemplos de saída no prompt.

O Kimi K2.7 cometeu o desvio de bloco de código em 1 de 3 rodadas.

O Kimi K3 retornou JSON puro em array nas 3 rodadas. Foi o único com conformidade integral e estável de formato.

16. Risco percebido de erro

Risco percebido em escala de 1 a 5: os três modelos obtiveram nota 2.

Erros críticos: zero para os três modelos.

Seguro para automação: 100% para os três modelos.

Análise: nenhum modelo cometeu erros críticos em nenhuma rodada válida. Todos os tickets foram analisados, sem omissões e sem alucinações de fatos. Os três modelos ficam com risco 2, classificado como baixo.

Cada modelo apresenta um motivo específico para o risco 2. O DeepSeek apresenta desvios de formato e menor consistência de classificação. O Kimi K2.7 apresenta superestimação recorrente de urgência e fence em 1 de 3 rodadas. O Kimi K3 apresenta superestimação de churn nas rodadas 2 e 3, além de latência elevada e variável.

Todos os falsos positivos observados, como urgência ou churn acima do gabarito, desperdiçam esforço de triagem, mas não causam perda de tickets. Trata-se do sentido mais seguro de errar.

17. Critérios eliminatórios

Os critérios eliminatórios utilizados foram: JSON válido maior ou igual a 98%, erros críticos menor ou igual a 5%, acurácia combinada de classificação maior ou igual a 80% na média das rodadas, e percentil 95 de latência dentro do limite aceitável para o produto. O limite de latência não foi definido pela equipe, portanto esse critério não foi avaliado.

JSON válido maior ou igual a 98%: DeepSeek V4 Flash foi reprovado com 33,3%. Kimi K2.7 foi reprovado com 66,7%. Kimi K3 foi aprovado com 100%.

Erros críticos menor ou igual a 5%: os três modelos foram aprovados com 0%.

Acurácia combinada maior ou igual a 80%: DeepSeek V4 Flash foi aprovado com 93,3%. Kimi K2.7 foi reprovado com 75%. Kimi K3 foi aprovado com 83,3%.

Percentil 95 dentro do limite: não avaliado para os três modelos.

Resultado nos critérios eliminatórios: DeepSeek V4 Flash foi reprovado. Kimi K2.7 foi reprovado. Kimi K3 foi aprovado.

Observação sobre o DeepSeek V4 Flash: o modelo foi reprovado exclusivamente no critério de formato. O conteúdo JSON era válido e completo em todas as rodadas, mas 2 de 3 vieram em bloco de código markdown e a rodada conforme usou envelope de objeto em vez de array. Trata-se de um desvio de apresentação mitigável, diferente de uma falha de qualidade. A reprovação não inviabiliza o modelo, mas exige correção antes da adoção.

O mesmo desvio, em menor grau, reprovou também o Kimi K2.7 no critério de formato.

18. Matriz de decisão

Os pesos utilizados foram: qualidade 30%, risco de erro 20%, custo 20%, latência 15%, consistência 10%, e adequação ao formato e tom 5%.

As notas foram normalizadas de 0 a 100 por critério. Custo e latência foram normalizados em escala relativa entre os três modelos. Risco foi invertido.

Na qualidade, DeepSeek V4 Flash obteve 100, Kimi K2.7 obteve 80 e Kimi K3 obteve 90.

No risco de erro, os três modelos obtiveram 75.

No custo, DeepSeek V4 Flash obteve 100, Kimi K2.7 obteve 83 e Kimi K3 obteve 0.

Na latência, DeepSeek V4 Flash obteve 96, Kimi K2.7 obteve 100 e Kimi K3 obteve 0.

Na consistência, DeepSeek V4 Flash obteve 40, Kimi K2.7 obteve 60 e Kimi K3 obteve 60.

Na adequação ao formato e tom, DeepSeek V4 Flash obteve 80, Kimi K2.7 obteve 80 e Kimi K3 obteve 100.

Pontuação final de 0 a 100: DeepSeek V4 Flash obteve 87,4. Kimi K2.7 obteve 80,7. Kimi K3 obteve 53,0.

19. Análise de trade-offs

O DeepSeek V4 Flash apresentou a melhor qualidade, com 93,3% de acurácia combinada média e rodadas de 100%, 85% e 95%. Ele ficou à frente do Kimi K3, com 83,3%, e do Kimi K2.7, com 75%. A amostra é pequena, mas a vantagem foi consistente nas 3 rodadas.

O DeepSeek V4 Flash no plano pago apresentou o menor custo, com 0,00022 dólar por ticket. Esse valor é cerca de 12 vezes menor que o do Kimi K2.7 e 69 vezes

menor que o do Kimi K3. A camada gratuita está disponível até 200 requisições por dia.

O Kimi K2.7 apresentou a menor latência, com média de 13,2 segundos. O DeepSeek ficou próximo, com 17,1 segundos. O Kimi K3 ficou muito atrás, com 110 segundos em média e picos de 148 segundos.

O Kimi K2.7 e o Kimi K3 empataram na maior consistência de classificação, com 60%. O DeepSeek ficou atrás, com 40%. Nenhum modelo é plenamente consistente nos tickets 2 e 4.

O Kimi K3 apresentou o melhor formato, com JSON puro em 3 de 3 rodadas e único sem desvios. O Kimi K2.7 ficou intermediário, com 2 de 3 rodadas. O DeepSeek apresentou fence em 2 de 3 rodadas e envelope alternativo na rodada conforme, mas o desvio é mitigável.

O risco foi igual entre os três modelos, com nota 2, e nenhum apresentou erros críticos.

Apenas o Kimi K3 foi integralmente aprovado nos critérios eliminatórios. O DeepSeek foi reprovado apenas no formato, por desvio mitigável. O Kimi K2.7 foi reprovado no formato, com 66,7%, e na acurácia combinada, com 75%.

O custo adicional do Kimi K3 não justifica a qualidade. O modelo é 69 vezes mais caro que o DeepSeek pago, mas teve qualidade média inferior, de 83,3% contra 93,3%. Ele apresenta a mesma consistência do Kimi K2.7 e latência muito pior. Sua única vantagem é o formato perfeito, que pode ser obtido no DeepSeek com tratamento de saída.

O DeepSeek pago elimina o teto da camada gratuita a custo quase irrelevante, de aproximadamente 1,1 mil dólar por milhão de execuções em lote. Isso preserva a margem em qualquer volume projetado.

Os três modelos são seguros para automação com revisão humana dos casos sinalizados como urgência alta ou crítica, ou churn médio ou alto. Os tickets dos perfis 2 e 4, de cobrança e usabilidade ambígua, merecem atenção especial por terem variado em todos os modelos.

Os dados sustentam uma estratégia híbrida, com modelo principal econômico e fallback, dispensando camada premium neste momento.

20. Recomendação final

Recomendação: adotar o DeepSeek V4 Flash no plano pago como modelo principal, com correção do desvio de formato e melhoria de consistência via calibragem do prompt, e usar o Kimi K2.7 como fallback.

Modelo principal: DeepSeek V4 Flash no plano pago. O modelo obteve a melhor pontuação ponderada, 87,4, a melhor qualidade média, 93,3% de acurácia combinada, custo de 0,00022 dólar por ticket sem teto de uso e latência adequada a processamento assíncrono, de aproximadamente 17 segundos.

Condições para adoção: mitigar os desvios de formato, como bloco de código em 2 de 3 rodadas e envelope alternativo na rodada conforme, usando parser tolerante ou exemplos de saída no prompt e validando a conformidade do JSON. Melhorar a consistência, que foi de 40%, com exemplos de calibragem de urgência e churn nos tickets dos perfis 2 e 4. Confirmar qualidade e consistência em rodada ampliada. Para volumes muito baixos, até 200 requisições por dia, a camada gratuita pode ser usada sem custo.

Fallback: Kimi K2.7. O modelo apresenta baixo custo, de 0,0027 dólar por ticket, e a menor latência média. Deve ser usado quando o principal estiver indisponível ou fora de conformidade. Ressalvas: foi reprovado em dois critérios eliminatórios, formato em 1 de 3 rodadas e acurácia combinada de 75%, com superestimação recorrente de urgência. Recomenda-se calibrar o prompt com exemplos antes do uso pleno.

Não recomendado como padrão neste momento: Kimi K3. O modelo é o único com formato perfeito e boa calibragem, mas apresenta qualidade média inferior à do DeepSeek, custo 69 vezes maior e latência de 81 a 148 segundos. É inviável para triagem em volume ou tempo real. Pode ser reavaliado como camada premium para casos críticos se rodadas futuras demonstrarem vantagem concreta nesses casos.

Revisão humana: obrigatória para tickets classificados como urgência alta ou crítica, ou risco de churn médio ou alto. A revisão é especialmente importante para os perfis que variaram em todos os modelos, como cobrança e usabilidade com sinal de churn.

Observação: dada a amostra pequena de 5 tickets e 3 execuções em lote por modelo, a decisão deve ser confirmada com uma rodada ampliada de 30 tickets, 3 repetições e execução individual por ticket, antes da implementação em produção.

21. Limitações

Desvio de execução: os 5 tickets foram enviados em um único prompt por execução, em formato de lote, em vez de uma execução individual por ticket. O plano original previa execuções individuais. Esse desvio pode ter afetado o comportamento dos modelos, inclusive a variação de envelope observada no DeepSeek, entre array e objeto por ticket.

Rodadas em planos distintos do DeepSeek: das 3 rodadas válidas do DeepSeek, 1 foi na camada gratuita e 2 no plano pago. As métricas de custo consideram apenas as rodadas pagas.

Primeira execução do DeepSeek descartada: houve suspeita de instabilidade de rede durante o primeiro teste. A execução foi refeita e não entrou nos cálculos. A latência do modelo pode ter sido afetada pela mesma instabilidade no período.

Amostra pequena: 5 tickets e 3 execuções por modelo são suficientes para a atividade acadêmica, mas não para uma decisão de produção.

Consistência medida em lote: a métrica reflete a estabilidade em execuções em lote. A consistência em execuções individuais pode ser diferente.

Parâmetros não controlados: temperatura e limite máximo de resposta não foram configurados no OpenCode.

Uso de cache variável: várias rodadas reutilizaram cache de sessão, com 9.600 e 9.088 tokens no DeepSeek e 8.448 tokens no Kimi K3. O cache reduziu custo e possivelmente afetou latência. O efeito nas respostas não é mensurável com os dados disponíveis.

Coluna Usage não documentada: a plataforma exibe 60 dólares na coluna Usage do DeepSeek V4 Flash. O significado desse valor, que pode ser pacote, crédito ou compromisso mínimo, não foi confirmado neste teste.

Preços e limites vigentes na data do teste: os preços por milhão de tokens e o limite de 200 requisições por dia da camada gratuita são os informados pela plataforma em 30 de julho de 2026. Esses valores podem mudar ou ser descontinuados.

Critério de percentil 95 sem limite definido: a equipe não definiu o limite aceitável de latência antes da execução. Com 3 rodadas, o percentil 95 foi apenas aproximado pelo maior valor observado.

Subjetividade do gabarito: urgência é o campo mais dependente de julgamento. Divergências entre modelos e gabarito podem ser razoáveis, como os tickets 1 e 2 classificados como alta pelos três modelos em ao menos uma rodada, contra media

no gabarito.

Avaliação humana não cega: o avaliador conhecia a identidade dos modelos.

22. Conclusão

O benchmark comparou DeepSeek V4 Flash, Kimi K2.7 e Kimi K3 na tarefa de análise automatizada de tickets, com dados reais de 3 execuções por modelo na plataforma OpenCode.

O DeepSeek V4 Flash no plano pago consolidou a melhor relação custo-benefício. Ele apresentou a melhor qualidade média do benchmark, com 93,3% de acurácia combinada, custo de apenas 0,00022 dólar por ticket sem teto de uso e latência adequada, de aproximadamente 17 segundos. Seus pontos fracos são claros e tratáveis: consistência de classificação de 40% e desvios de formato em 2 de 3 rodadas.

O Kimi K2.7 confirmou boa latência e baixo custo, mas a superestimação recorrente de urgência o reprovou no critério de qualidade. O Kimi K3 confirmou o formato perfeito, mas apresentou qualidade média inferior à do DeepSeek, custo 69 vezes maior e latência de 81 a 148 segundos. Nenhuma vantagem do Kimi K3 justifica a diferença.

A recomendação é adotar o DeepSeek V4 Flash no plano pago como modelo principal, condicionado à mitigação dos desvios de formato e à melhoria de consistência via calibragem do prompt. O Kimi K2.7 deve ser usado como fallback, com revisão humana dos casos de alto risco e dos perfis de ticket que variaram em todos os modelos. A decisão deve ser confirmada por uma rodada ampliada de testes antes da implementação em produção.